



PROGRAMME DE FORMATION

Ingénierie des données sur AWS

Ingérer, transformer, gouverner et analyser des données sur AWS

27 HEURES

POUR Analystes de données, développeurs et ingénieurs qui construisent des pipelines de données sur AWS

PRÉPARE À AWS Certified Data Engineer – Associate (DEA-C01), thèmes principaux



Mohamed Aziz BEN HAHHA

mohamedazizbenhaha.netlify.app

Présentation

Ce programme apprend aux participants à construire des pipelines de données sur Amazon Web Services et couvre les thèmes principaux de l'examen AWS Certified Data Engineer – Associate (DEA-C01). Ils conçoivent un data lake S3 avec des tables Parquet partitionnées et Apache Iceberg, ingèrent des données par lots et en flux, les transforment avec AWS Glue et EMR, chargent et interrogent Amazon Redshift Serverless, gouvernent accès et qualité avec Lake Formation et Glue Data Quality, orchestrent avec Step Functions et Amazon MWAA, et analysent les résultats avec Athena, Amazon Managed Service for Apache Flink et QuickSight. Un entraînement à l'examen clôt le contenu, et le programme s'achève par un projet final : un pipeline de données de bout en bout construit et présenté par chaque équipe.

Vue d'ensemble

#	PHASE	THÈMES	HEURES
01	Data lakes et ingestion	Lake, entrepôt et lakehouse, formats S3 et Iceberg, ingestion par lots et en flux	6 h
02	Traitement et entreposage	AWS Glue, EMR, Amazon Redshift Serverless	6 h
03	Gouvernance, orchestration et analyse	Lake Formation, qualité des données, Step Functions, MWAA, Athena, Flink, QuickSight	6 h
04	Projet final	Un pipeline de données de bout en bout, présenté au groupe	6 h
	Réserve	Rattrapage, révision, TP supplémentaires	3 h
	Total		27 h

Informations clés

PUBLIC	Analystes de données, développeurs et ingénieurs qui construisent des pipelines de données sur AWS
PRÉREQUIS	Services AWS essentiels (cours : AWS Cloud Practitioner) ; Python et SQL (cours : Python pour la data science), ou équivalent. Ces notions sont utilisées, pas enseignées
DURÉE	27 h : 24 h de chapitres + 3 h de réserve
FORMAT	Cours courts suivis de TP guidés sur un jeu de données commun ; entraînement à l'examen
ENVIRONNEMENT DE TP	Un portable par participant avec un navigateur et la CLI AWS ; un compte AWS de test par équipe, fourni par l'organisateur, avec alerte budgétaire ; MWAA et l'abonnement QuickSight préparés par l'organisateur pour le cours, Redshift Serverless à la capacité de base minimale ; flux, clusters et entrepôts supprimés à la fin de chaque TP
ÉVALUATION	Un TP validé à la fin de chaque phase, des questions d'entraînement à l'examen et un projet final présenté au groupe ; attestation de formation pour les participants qui valident les TP et le projet
RÉSULTAT	Les participants savent construire un pipeline orchestré qui ingère, catalogue, transforme, gouverne et met à disposition des données sur AWS, et expliquer ses choix de conception

PHASE 01

6 H

Data lakes et ingestion

Les participants comparent traitement par lots et en flux, data lakes, entrepôts et lakehouses, conçoivent un data lake S3 avec des tables Parquet partitionnées et Apache Iceberg, puis ingèrent des données avec Kinesis Data Streams, Amazon Data Firehose, DMS et AppFlow, avec une présentation d'Amazon MSK. TP validé : un flux de clics (clickstream) envoyé dans Kinesis Data Streams et livré par Firehose en fichiers JSON partitionnés par date dans la zone brute du data lake.

#	CHAPITRE	CONTENU	FORMAT	HEURES
1.1	Fondamentaux de l'ingénierie des données	Lots et flux, data lake, entrepôt et lakehouse	Cours + atelier	1,5 h
1.2	Stockage et formats	Data lake S3, partitionnement, Parquet, tables Apache Iceberg (dont Amazon S3 Tables)	Cours + TP	1,5 h
1.3	Ingestion	Kinesis Data Streams, Amazon Data Firehose, DMS, AppFlow, présentation d'Amazon MSK	Cours + TP	3 h

PHASE 02

6 H

Traitement et entreposage

Les participants cataloguent et transforment le data lake avec les crawlers, le Data Catalog et les jobs ETL d’AWS Glue, voient quand EMR est le meilleur choix, puis conçoivent, chargent et interrogent un entrepôt Redshift Serverless. TP validé : un job Glue qui nettoie les données brutes vers une table Iceberg nettoyée, chargée dans Redshift Serverless et interrogée.

#	CHAPITRE	CONTENU	FORMAT	HEURES
2.1	Traitement	AWS Glue (jobs ETL, crawlers, Data Catalog), EMR	Cours + TP	3 h
2.2	Entreposage de données	Conception, chargement et interrogation d’Amazon Redshift Serverless	Cours + TP	3 h

PHASE 03

6 H

Gouvernance, orchestration et analyse

Les participants contrôlent qui voit quelles données avec Lake Formation, les vérifient avec Glue Data Quality et en tracent le lignage, orchestrent le pipeline avec Step Functions et Amazon MWAA, l'analysent avec Athena, Managed Service for Apache Flink et QuickSight, puis s'entraînent sur des questions DEA-C01. TP validé : une exécution orchestrée qui s'arrête quand une règle de qualité échoue, et un rôle d'analyste qui ne peut interroger que ses colonnes autorisées dans Athena.

#	CHAPITRE	CONTENU	FORMAT	HEURES
3.1	Gouvernance et qualité	Permissions Lake Formation, Glue Data Quality, lignage des données (Amazon DataZone / SageMaker Catalog)	Cours + TP	1,5 h
3.2	Orchestration	Step Functions, Amazon MWAA (Apache Airflow)	Cours + TP	1,5 h
3.3	Analyse et traitement en temps réel	Athena, Amazon Managed Service for Apache Flink, QuickSight	Cours + TP	1,5 h
3.4	Préparation au DEA-C01	Questions d'entraînement et révision	Cours + atelier	1,5 h

PHASE 04

6 H

Projet final

Par équipes de deux ou trois, les participants construisent un pipeline complet pour un jeu de données fourni, en réutilisant les TP de phase, puis le présentent comme ils le feraient devant un responsable data et suppriment les ressources.

#	CHAPITRE	CONTENU	FORMAT	HEURES
4.1	Cahier des charges et réalisation	Analyser le besoin, ingérer avec Kinesis et S3, cataloguer et transformer avec Glue, interroger avec Athena	Projet	3 h
4.2	Mise à disposition et orchestration	Charger Redshift Serverless, construire le tableau de bord QuickSight, orchestrer avec Step Functions ; schéma d'architecture	Projet	1,5 h
4.3	Démonstration et suppression	Exécution en direct du pipeline, présentation du tableau de bord, suppression des ressources ; questions et retours	Projet	1,5 h

PROJET FINAL

Un pipeline de données de bout en bout sur AWS

Des données ingérées avec Kinesis et S3, cataloguées et transformées avec Glue, interrogées avec Athena, chargées dans Redshift Serverless et affichées sur un tableau de bord QuickSight, l'ensemble orchestré par Step Functions et supprimé après la démonstration.

OUTILS AWS : S3, Kinesis Data Streams, Amazon Data Firehose, Glue, Athena, Redshift Serverless, Lake Formation, Step Functions, QuickSight ; Python, SQL

LIVRABLE Code du pipeline, schéma d'architecture, tableau de bord, démonstration en direct