



PROGRAMME DE FORMATION

Ingénierie du machine learning sur AWS

Préparer les données, entraîner, déployer, automatiser et superviser des modèles avec SageMaker AI

45 HEURES

POUR Data scientists et ingénieurs qui mettent des modèles de machine learning en production sur AWS

PRÉPARE À AWS Certified Machine Learning Engineer – Associate (MLA-C01)



Mohamed Aziz BEN HAHA

mohamedazizbenhaha.netlify.app

Présentation

Ce programme apprend aux participants à construire et exploiter des systèmes de machine learning sur Amazon SageMaker AI et prépare l'examen AWS Certified Machine Learning Engineer – Associate (MLA-C01). Ils préparent et étiquettent les données, construisent les variables et vérifient les biais, entraînent et optimisent les modèles, les déploient sur des endpoints et par transformation par lots, automatisent le cycle de vie avec SageMaker Pipelines et le Model Registry, supervisent dérive et coûts, sécurisent les charges de travail, et mettent l'IA générative en production avec Bedrock. Un entraînement à l'examen clôt le contenu, et le programme s'achève par un système de ML en production construit et présenté par chaque équipe.

Vue d'ensemble

#	PHASE	THÈMES	HEURES
01	Infrastructure de ML et préparation des données	Infrastructure SageMaker AI, ingestion, Data Wrangler, Feature Store, contrôle des biais	9 h
02	Développement des modèles	Algorithmes intégrés, script mode, entraînement distribué, optimisation, évaluation	6 h
03	Déploiement et MLOps	Endpoints, mise à l'échelle automatique, SageMaker Pipelines, Model Registry, CI/CD, supervision	9 h
04	Sécurité, IA générative et préparation à l'examen	Moindre privilège, isolation VPC, chiffrement, Bedrock en production, MLA-C01	9 h
05	Projet final	Un système de ML en production sur SageMaker AI, présenté au groupe	6 h
	Réserve	Rattrapage, révision, TP supplémentaires	6 h
	Total		45 h

Informations clés

PUBLIC	Data scientists et ingénieurs qui mettent des modèles de machine learning en production sur AWS
PRÉREQUIS	Machine learning (cours : Machine learning et deep learning) et services d'IA AWS (cours : AWS AI Practitioner et IA générative), avec les services AWS essentiels (cours : AWS Cloud Practitioner), ou équivalent
DURÉE	45 h : 39 h de chapitres + 6 h de réserve
FORMAT	Cours courts suivis de TP guidés dans SageMaker Studio ; un même modèle repris dans toutes les phases ; entraînement à l'examen
ENVIRONNEMENT DE TP	Un portable par participant avec un navigateur ; un compte AWS de test par équipe (domaine SageMaker AI, quota GPU, alerte budgétaire) fourni par l'organisateur ; endpoints supprimés et sessions Canvas fermées à la fin de chaque TP
ÉVALUATION	Un TP validé par phase, des questions d'entraînement et un projet final présenté au groupe ; attestation de formation si les TP et le projet sont validés
RÉSULTAT	Les participants savent construire un pipeline automatisé de la préparation des données à un endpoint supervisé sur SageMaker AI, le sécuriser, et se présenter à l'examen MLA-C01

PHASE 01

9 H

Infrastructure de ML et préparation des données

Les participants mettent en place l'infrastructure utilisée par toutes les phases suivantes : un domaine SageMaker AI, des rôles d'exécution, S3, des instances GPU et FSx. Ils ingèrent et préparent ensuite les données avec Glue et Data Wrangler, enregistrent les variables dans Feature Store et vérifient les biais des données avec Clarify avant l'entraînement. TP validé : un groupe de variables dans Feature Store construit à partir de données brutes, avec un rapport de biais Clarify avant entraînement.

#	CHAPITRE	CONTENU	FORMAT	HEURES
1.1	Infrastructure de ML	Domaines SageMaker AI, rôles d'exécution IAM, S3, instances GPU, FSx	Cours + TP	3 h
1.2	Ingestion et préparation des données	Glue et Glue DataBrew, Data Wrangler dans SageMaker Canvas, ingestion en flux (Kinesis), formats de données (Parquet, CSV, RecordIO), qualité des données, étiquetage avec Ground Truth	Cours + TP	3 h
1.3	Ingénierie des variables et biais	Feature Store, transformations, déséquilibre des classes, traitement des données personnelles, biais avant entraînement avec Clarify	Cours + TP	3 h

PHASE 02

6 H

Développement des modèles

Les participants entraînent des modèles avec les algorithmes intégrés et leur propre code de framework en script mode, répartissent l'entraînement sur plusieurs instances, suivent les expériences, puis optimisent automatiquement les hyperparamètres et évaluent et expliquent les résultats. TP validé : un job d'optimisation dont le meilleur modèle bat la référence sur la métrique d'évaluation, avec un rapport d'explicabilité Clarify.

#	CHAPITRE	CONTENU	FORMAT	HEURES
2.1	Entraînement	Choix entre services d'IA, Bedrock, JumpStart ou entraînement personnalisé ; algorithmes intégrés, script mode, entraînement sur instances Spot, entraînement distribué, SageMaker Debugger, expériences avec MLflow managé	Cours + TP	3 h
2.2	Optimisation et évaluation	Optimisation automatique des modèles, métriques d'évaluation, Clarify	Cours + TP	3 h

PHASE 03

9 H

Déploiement et MLOps

Les participants choisissent la bonne option d'inférence, endpoints temps réel, serverless et asynchrones et transformation par lots, avec mise à l'échelle automatique, automatisent le cycle de vie avec SageMaker Pipelines, le Model Registry et la CI/CD, puis surveillent la production avec Model Monitor, la détection de dérive, CloudWatch et la maîtrise des coûts. TP validé : un pipeline qui enregistre un modèle, le déploie après approbation et déclenche une alerte quand les données d'entrée dérivent.

#	CHAPITRE	CONTENU	FORMAT	HEURES
3.1	Déploiement	Endpoints temps réel, serverless et asynchrones, transformation par lots (batch transform), endpoints multi-modèles, Inference Recommender, conteneurs personnalisés dans ECR, mise à l'échelle automatique	Cours + TP	3 h
3.2	MLOps	SageMaker Pipelines, Model Registry, CloudFormation et CDK, EventBridge, CodePipeline ; déploiements blue/green, canary et shadow	Cours + TP	3 h
3.3	Supervision et coûts	Model Monitor (qualité des données, qualité du modèle, dérive des biais et des attributions), tests A/B, CloudWatch, CloudTrail, Cost Explorer, Savings Plans et Spot	Cours + TP	3 h

PHASE 04

9 H

Sécurité, IA générative et préparation à l'examen

Les participants sécurisent les charges de travail de ML avec IAM au moindre privilège, l'isolation VPC et le chiffrement, mettent l'IA générative en production avec l'affinage Bedrock, les Knowledge Bases et les Agents, puis s'entraînent sur des questions MLA-C01. TP validé : un job d'entraînement et un endpoint qui tournent sans accès Internet dans un VPC, avec données et artefacts de modèle chiffrés.

#	CHAPITRE	CONTENU	FORMAT	HEURES
4.1	Sécurité pour le ML	IAM au moindre privilège, isolation VPC, chiffrement, conformité	Cours + TP	3 h
4.2	IA générative en production	Personnalisation Bedrock (un petit affinage, inférence à la demande), Knowledge Bases, Agents	Cours + TP	3 h
4.3	Préparation au MLA-C01	Questions d'entraînement et révision	Cours + atelier	3 h

PHASE 05

6 H

Projet final

Par équipes de deux ou trois, les participants construisent un système de ML en production pour un cas d'usage fourni, en réutilisant les TP de phase, puis le présentent comme ils le feraient devant un responsable data.

#	CHAPITRE	CONTENU	FORMAT	HEURES
5.1	Cahier des charges et réalisation	Analyser le besoin, construire le pipeline de la préparation des données au Model Registry	Projet	3 h
5.2	Déploiement et supervision	Déploiement automatisé, alertes de dérive, une fonctionnalité appuyée sur Bedrock ; schéma d'architecture	Projet	1,5 h
5.3	Démonstration et revue	Exécution en direct du pipeline et d'une alerte de dérive, suppression des ressources ; questions et retours	Projet	1,5 h

PROJET FINAL

Un système de ML en production sur SageMaker AI

Un pipeline SageMaker de la préparation des données au Model Registry, un déploiement automatisé sur un endpoint, des alertes de dérive en production, et une fonctionnalité appuyée sur Amazon Bedrock.

OUTILS AWS : SageMaker AI (Studio, Pipelines, Model Registry, Model Monitor, Clarify, Feature Store), Glue, S3, CloudWatch, Amazon Bedrock

LIVRABLE Code du pipeline, schéma d'architecture, tableau de bord de supervision, démonstration en direct