



PROGRAMME DE FORMATION

NLP : du traitement de texte aux Transformers

Traiter, représenter, classer et extraire l'information de textes en français, en anglais et en arabe

27 HEURES

POUR Data scientists et développeurs qui travaillent avec des données textuelles



Mohamed Aziz BEN HAH

mohamedazizbenhaha.netlify.app

Présentation

Ce programme fait parcourir aux participants le traitement automatique des langues, du traitement de texte classique aux Transformers et aux grands modèles de langage. Ils nettoient et segmentent le texte, le représentent par sacs de mots, TF-IDF et plongements lexicaux, construisent des classifieurs pour le sentiment et d'autres tâches, extraient entités et relations, et découvrent des thèmes. Ils affinent ensuite des modèles BERT avec Hugging Face, traitent des textes multilingues en portant attention à l'arabe et au français, et comparent les LLM en zero-shot et few-shot aux modèles affinés. Chaque chapitre se termine par un TP, et le programme s'achève par un projet final : une application de NLP sur des textes multilingues, construite et présentée par chaque équipe.

Vue d'ensemble

#	PHASE	THÈMES	HEURES
01	Traitement et représentation du texte	Tâches de NLP, segmentation, normalisation, sacs de mots, TF-IDF, plongements lexicaux	6 h
02	Tâches classiques du NLP	Classification et sentiment, entités nommées et relations, modélisation thématique	6 h
03	Transformers et LLM	Affinage de BERT, NLP multilingue, LLM pour les tâches de NLP	6 h
04	Projet final	Une application de NLP multilingue, présentée au groupe	6 h
	Réserve	Rattrapage, révision, TP supplémentaires	3 h
	Total		27 h

Informations clés

PUBLIC	Data scientists et développeurs qui travaillent avec des données textuelles
PRÉREQUIS	Python et pandas (cours : Python pour la data science) et bases du deep learning (cours : Machine learning et deep learning, phase deep learning), ou équivalent. Ces notions sont utilisées, pas enseignées
DURÉE	27 h : 24 h de chapitres + 3 h de réserve
FORMAT	Cours courts suivis de TP guidés dans Jupyter sur des corpus en français, en anglais et en arabe
ENVIRONNEMENT DE TP	Un portable par participant (16 Go de RAM, Python 3, JupyterLab, spaCy, NLTK, Hugging Face) ; notebooks GPU sur Google Colab ou serveur GPU fourni par l'organisateur pour l'affinage ; un LLM ouvert via Ollama ou sur le serveur GPU, ou une clé d'API de LLM hébergé par équipe avec plafond de dépenses, fournie par l'organisateur
ÉVALUATION	Un TP validé à la fin de chaque phase et un projet final présenté au groupe ; attestation de formation pour les participants qui valident les deux
RÉSULTAT	Les participants savent construire, affiner et évaluer des modèles de NLP de classification et d'extraction sur des textes en français, en anglais et en arabe, et juger quand un LLM est le meilleur outil

PHASE 01

6 H

Traitement et représentation du texte

Les participants voient à quoi sert le NLP, puis transforment le texte brut en tokens propres avec spaCy, NLTK et les expressions régulières, et en nombres avec les sacs de mots, TF-IDF, word2vec et GloVe. TP validé : une chaîne de prétraitement pour des avis en français et en anglais, et les plus proches voisins de mots choisis dans un espace de plongements.

#	CHAPITRE	CONTENU	FORMAT	HEURES
1.1	Introduction et traitement du texte	Tâches et applications, segmentation en tokens, normalisation, racinisation et lemmatisation, expressions régulières, spaCy et NLTK	Cours + TP	3 h
1.2	Représentation du texte	Sacs de mots, TF-IDF, word2vec, GloVe	Cours + TP	3 h

PHASE 02

6 H

Tâches classiques du NLP

Les participants construisent des classifieurs classiques et neuronaux pour le sentiment et d'autres étiquettes, extraient entités nommées et relations, et découvrent les thèmes d'un corpus avec LDA et BERTopic. TP validé : un classifieur de sentiment évalué sur un jeu réservé, et les principaux thèmes d'un corpus d'actualités trouvés avec LDA.

#	CHAPITRE	CONTENU	FORMAT	HEURES
2.1	Classification et sentiment	Classifieurs classiques et neuronaux	Cours + TP	3 h
2.2	Extraction d'information	Entités nommées, relations	Cours + TP	1,5 h
2.3	Modélisation thématique	LDA ; BERTopic en avant-goût des plongements Transformer	Cours + TP	1,5 h

Transformers et LLM

Les participants affinent des modèles de la famille BERT avec Hugging Face, traitent la traduction et les spécificités des textes arabes et français, puis utilisent des LLM en zero-shot et few-shot pour la classification et l'extraction, et les comparent aux modèles affinés. TP validé : la même tâche de classification résolue par un modèle multilingue affiné et par un LLM, avec exactitude et coût comparés.

#	CHAPITRE	CONTENU	FORMAT	HEURES
3.1	Transformers pour le NLP	BERT, affinage avec Hugging Face	Cours + TP	3 h
3.2	NLP multilingue	Traduction, spécificités de l'arabe et du français	Cours + TP	1,5 h
3.3	LLM pour les tâches de NLP	Classification et extraction en zero-shot et few-shot, évaluation face aux modèles affinés	Cours + TP	1,5 h

PHASE 04

6 H

Projet final

Par équipes de deux ou trois, les participants construisent une application de NLP de classification ou d'extraction sur des textes en arabe, en français ou en anglais, en réutilisant les TP de phase, puis la présentent comme ils le feraient devant une équipe produit.

#	CHAPITRE	CONTENU	FORMAT	HEURES
4.1	Cahier des charges et réalisation	Analyser le besoin, préparer le corpus, construire une référence et affiner un modèle Transformer	Projet	3 h
4.2	Évaluation et documentation	Évaluation par langue, analyse des erreurs, comparaison avec un LLM, court rapport	Projet	1,5 h
4.3	Démonstration et revue	Démonstration en direct sur de nouveaux textes ; questions et retours	Projet	1,5 h

PROJET FINAL

Une application de NLP multilingue

Une application qui classe des textes ou en extrait l'information dans des documents en arabe, en français ou en anglais avec un modèle Transformer affiné, évaluée par langue et comparée à une référence et à un LLM.

OUTILS Python, spaCy, Hugging Face Transformers et Datasets, scikit-learn, PyTorch, JupyterLab

LIVRABLE Dépôt avec notebooks et modèle, rapport d'évaluation, démonstration en direct