



PROGRAMME DE FORMATION

Python pour la data science

Explorer, interroger et visualiser des données avec Python, pandas et SQL

21 HEURES

POUR Analystes, étudiants et développeurs qui travaillent avec des données



Mohamed Aziz BEN HAHHA

mohamedazizbenhaha.netlify.app

Présentation

Ce programme donne aux participants la pile de données Python utilisée en analyse de données et en machine learning. Ils ajoutent les fonctionnalités de Python sur lesquelles repose le code de données, travaillent de façon reproductible dans Jupyter, calculent avec les tableaux NumPy, nettoient, remodelent et combinent les données avec pandas, interrogent des bases de données en SQL depuis Python, et communiquent leurs résultats avec Matplotlib, Seaborn et Plotly. Chaque chapitre se termine par des exercices sur des jeux de données réels, et le programme s'achève par un projet final où chaque participant livre un rapport d'analyse exploratoire sous forme de notebook Jupyter.

Vue d'ensemble

#	PHASE	THÈMES	HEURES
01	Outils et NumPy	Python pour les données, Jupyter et reproductibilité, tableaux NumPy	6 h
02	Pandas, SQL et visualisation	DataFrames, nettoyage et remodelage, requêtes SQL depuis Python, graphiques	9 h
03	Projet final	Un rapport d'analyse exploratoire sur un jeu de données réel	3 h
	Réserve	Rattrapage, révision, TP supplémentaires	3 h
	Total		21 h

Informations clés

PUBLIC	Analystes, étudiants et développeurs qui travaillent avec des données
PRÉREQUIS	Bases de Python (cours : Fondamentaux de la programmation Python, ou équivalent) : variables, structures de données, fonctions. Ces notions ne sont pas réenseignées
DURÉE	21 h : 18 h de chapitres + 3 h de réserve
FORMAT	Cours courts avec programmation en direct dans Jupyter, chacun suivi d'exercices sur des jeux de données réels
ENVIRONNEMENT DE TP	En local : un portable par participant avec Python 3, JupyterLab, pandas, NumPy, Matplotlib, Seaborn, Plotly et SQLite ; une base PostgreSQL fournie par l'organisateur ; Google Colab en solution de repli ; ni compte ni coût
ÉVALUATION	Exercices validés à la fin de chaque phase et un rapport d'analyse final présenté au groupe ; attestation de formation pour les participants qui valident les deux
RÉSULTAT	Les participants savent charger, nettoyer, interroger, analyser et visualiser un jeu de données réel avec Python, pandas et SQL, et présenter leurs résultats dans un notebook reproductible

PHASE 01

6 H

Outils et NumPy

Les participants ajoutent les fonctionnalités de Python utilisées chaque jour dans le code de données, travaillent dans JupyterLab et Colab de façon que d'autres puissent relancer leur travail, puis calculent avec les tableaux NumPy grâce à la vectorisation, au broadcasting et à l'algèbre linéaire. Exercice validé : un notebook qui simule et résume un jeu de données avec du code NumPy vectorisé et se relance proprement du début à la fin.

#	CHAPITRE	CONTENU	FORMAT	HEURES
1.1	Python pour les données	Compréhensions, lambdas, décorateurs, générateurs, annotations de type, dataclasses	Cours + TP	1,5 h
1.2	Jupyter et reproductibilité	JupyterLab, commandes magiques, nbconvert, Colab	Cours + TP	1,5 h
1.3	NumPy	ndarrays, vectorisation, broadcasting, algèbre linéaire	Cours + TP	3 h

PHASE 02

9 H

Pandas, SQL et visualisation

Les participants chargent, nettoient, filtrent, regroupent, fusionnent et remodèlent des données avec pandas, interrogent des bases SQLite et PostgreSQL en SQL et ramènent les résultats dans pandas, puis choisissent et construisent le bon graphique avec Matplotlib, Seaborn et Plotly. Exercice validé : une question sur un jeu de données de ventes traitée une fois en SQL et une fois avec pandas, et présentée dans un graphique clair.

#	CHAPITRE	CONTENU	FORMAT	HEURES
2.1	Pandas	DataFrames, lecture et écriture, filtrage, groupby, fusion, tableaux croisés, valeurs manquantes	Cours + TP	3 h
2.2	SQL pour l'analyse de données	SELECT, jointures, GROUP BY, fonctions de fenêtrage ; interroger SQLite et PostgreSQL depuis Python et pandas	Cours + TP	3 h
2.3	Visualisation	Matplotlib, Seaborn, Plotly	Cours + TP	3 h

PHASE 03

3 H

Projet final

Chaque participant analyse un jeu de données public réel, en réutilisant les exercices des phases, et présente ses résultats comme il le ferait devant un manager qui doit décider.

#	CHAPITRE	CONTENU	FORMAT	HEURES
3.1	Exploration et analyse	Charger et nettoyer le jeu de données, répondre aux questions du cahier des charges avec SQL et pandas, construire les graphiques	Projet	1,5 h
3.2	Rapport et présentation	Finaliser le notebook en rapport, présenter les résultats ; questions et retours	Projet	1,5 h

PROJET FINAL

Rapport d'analyse exploratoire

Un jeu de données public réel chargé, nettoyé, interrogé avec SQL et pandas, et exploré par des graphiques, livré sous forme de notebook Jupyter qui expose les questions, la méthode et les résultats.

OUTILS Python 3, JupyterLab, pandas, NumPy, SQLite ou PostgreSQL, Matplotlib, Seaborn, Plotly

LIVRABLE Rapport sous forme de notebook Jupyter, présentation des résultats